LICENCIATURA EN GESTIÓN DE TI — INTELIGENCIA DE NEGOCIOS, 2026

# Clasificación de la gravedad de los siniestros viales en la Ciudad de Buenos Aires, 2019-2025.

**Estudiante:** Santiago Baldini Cuevas.

**Docente:** Ernesto Aguaysol.

Universidad Nacional de José C. Paz.

El análisis, el código y este documento se hicieron con el modelo Grok 4.7.




## Abstract

Este trabajo clasifica los siniestros viales con víctimas registrados en la Ciudad de Buenos Aires por el Observatorio de Movilidad y Seguridad Vial entre el 1 de enero de 2019 y el 31 de diciembre de 2025. La pregunta es si un hecho ya ocurrido fue leve, grave o mortal. El archivo de hechos reúne 65.818 siniestros y pesa 12,2 MB. De ellos, 62.174 son leves, 2.955 graves y 689 mortales, cerca del 1 %. Con esa proporción, responder siempre «leve» acierta el 94,5 % y no encuentra ni un grave ni una muerte, así que el acierto global no alcanza para elegir un modelo. La notebook de análisis muestra la caída de hechos en 2020, una tasa más alta entre peatones que entre motos, una tasa más alta en autopista que en calle, y una tasa de madrugada varias veces mayor que la de la tarde. Esas métricas deciden el preprocesado: el hueco de la hora se marca con un indicador, el faltante de las categorías queda como SIN_DATO, y el desbalance se trata con un peso de clase de 31,85 para el mortal, 7,42 para el grave y 0,35 para el leve. Sobre esa matriz se ajustan una regresión logística, un árbol de decisión de profundidad 5 y un random forest de 200 árboles. En la prueba, de 13.164 hechos, el forest es el elegido por el recall macro: 62,1 %. Encuentra 117 de 138 muertes y 276 de 591 graves. El análisis, el código y este documento se hicieron con el modelo Grok 4.7.

# Alcance del modelo y aporte a la gestión

## Qué hace el trabajo

- **Objetivo:** Predice gravedad leve, grave o mortal en hechos ocurridos.
- **Variables:** Mes, día, hora, comuna, vía, modo y contraparte.
- **Límite predictivo:** No predice choques futuros ni vehículo de la víctima.
- **Límite legal:** Describe el hecho sin asignar culpables ni sentencia.

## Qué aporta al Gobierno de la Ciudad

- **Lectura de base:** Evita el sesgo del conteo dominado por hechos leves.
- **Concentración:** Moto suma más muertes; peatón, autopista y madrugada mayor tasa.
- **Gestión vial:** Orienta qué combinación de hora, vía y modo priorizar.
- **Uso del modelo:** Baja precisión; sirve para recuperar casos, no afirmarlos.

# Archivo original, definiciones y desbalanceo

- **Fuente:** Observatorio de Movilidad y Seguridad Vial GCBA (65.818 filas, 12.198.322 bytes).
- **Cobertura:** 1/1/2019 al 31/12/2025; una fila por siniestro; CSV víctimas (4,1 MB) no se usa.
- **Escala:** Mortal (fallece ≤ 30 días), Grave (≥ 24 h hospital), Leve (< 24 h).
- **Conteo:** 689 hechos mortales (14 con dos muertes, 703 víctimas mortales).

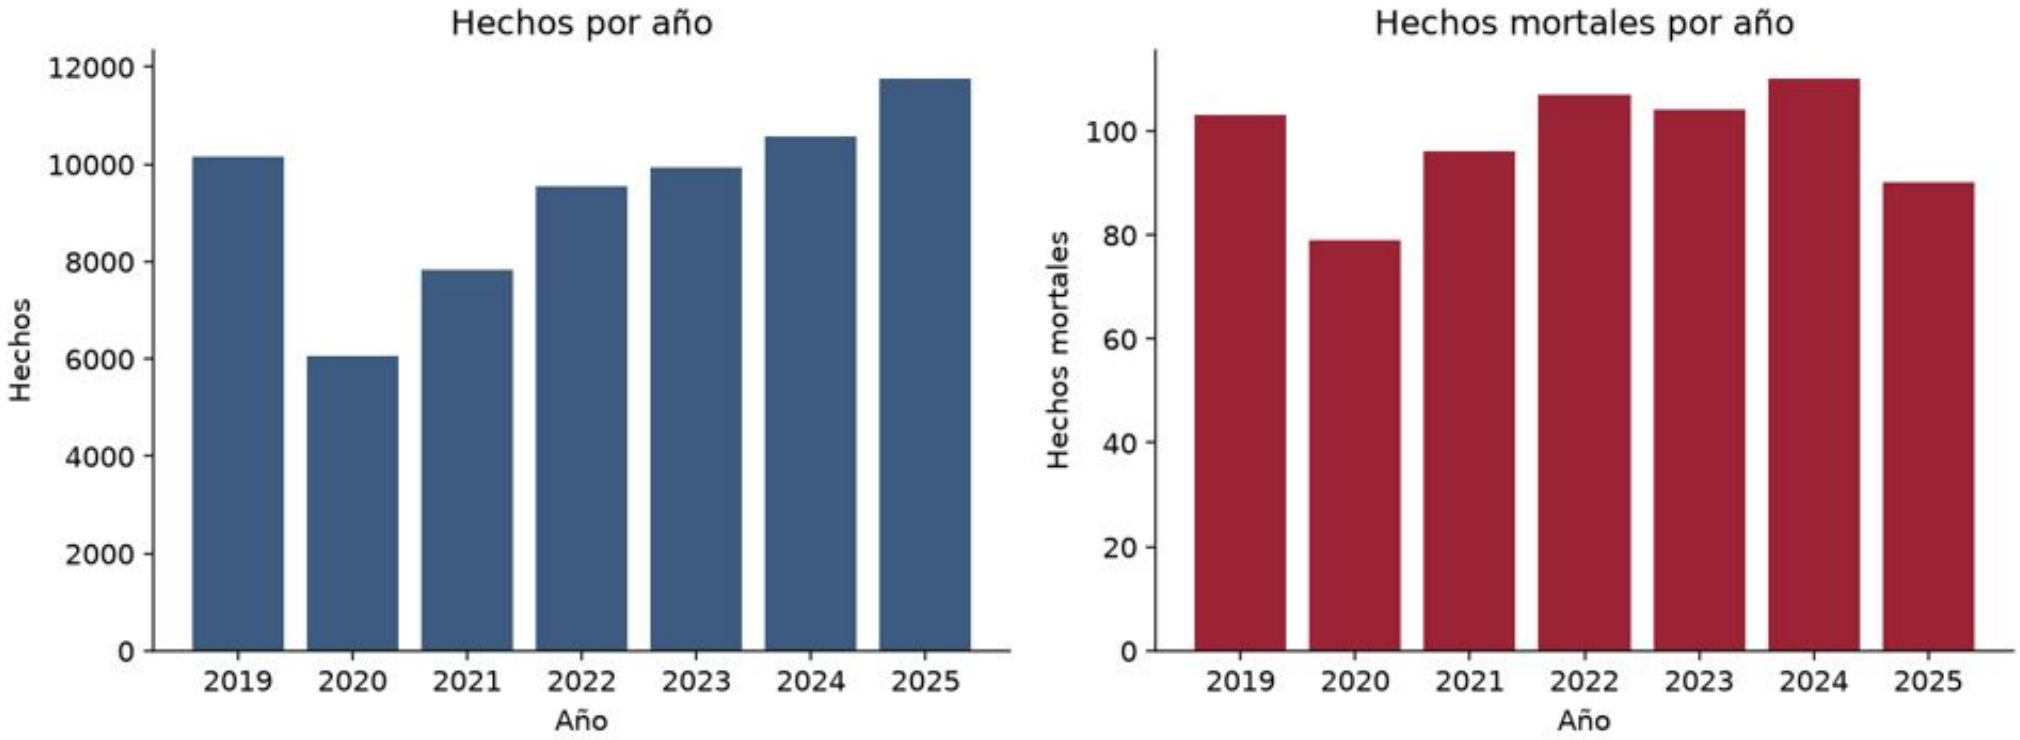
**[IMAGEN: diagramas/05_jerarquia.svg]**

Figura 1. Encoding jerárquico. Los conteos se resumen con el máximo de la escala, y el modelo predice uno de los tres niveles.



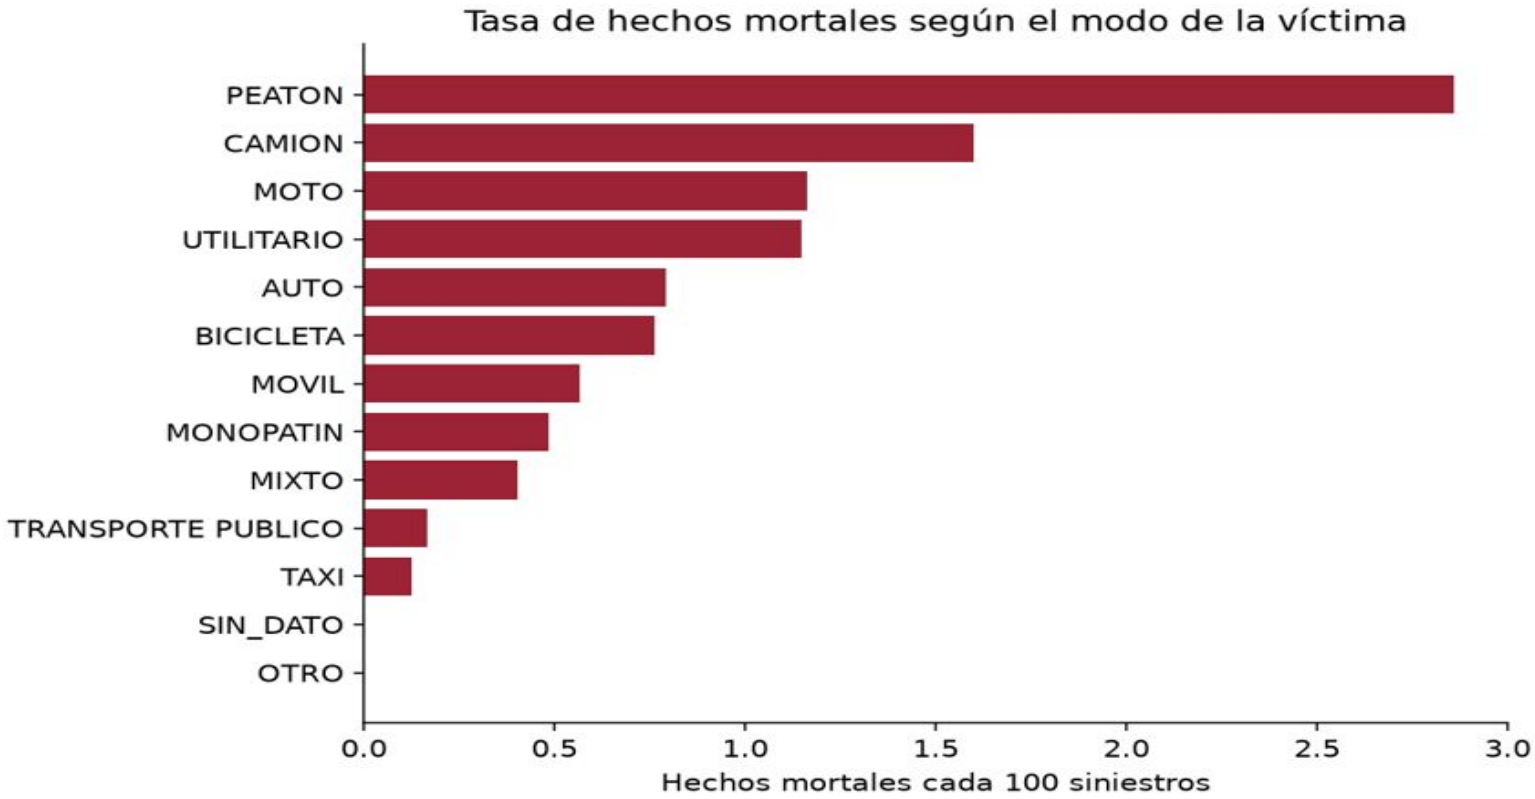

Figura 2. Conteo de hechos por gravedad. De 65.818 hechos, 62.174 son leves (94,5 %), 2.955 graves (4,5 %) y 689 mortales (1,0 %). El eje es un conteo: la barra leve es alta porque hay muchos hechos, no porque el riesgo sea alto.

# Evolución anual, modo de desplazamiento y tipo de vía



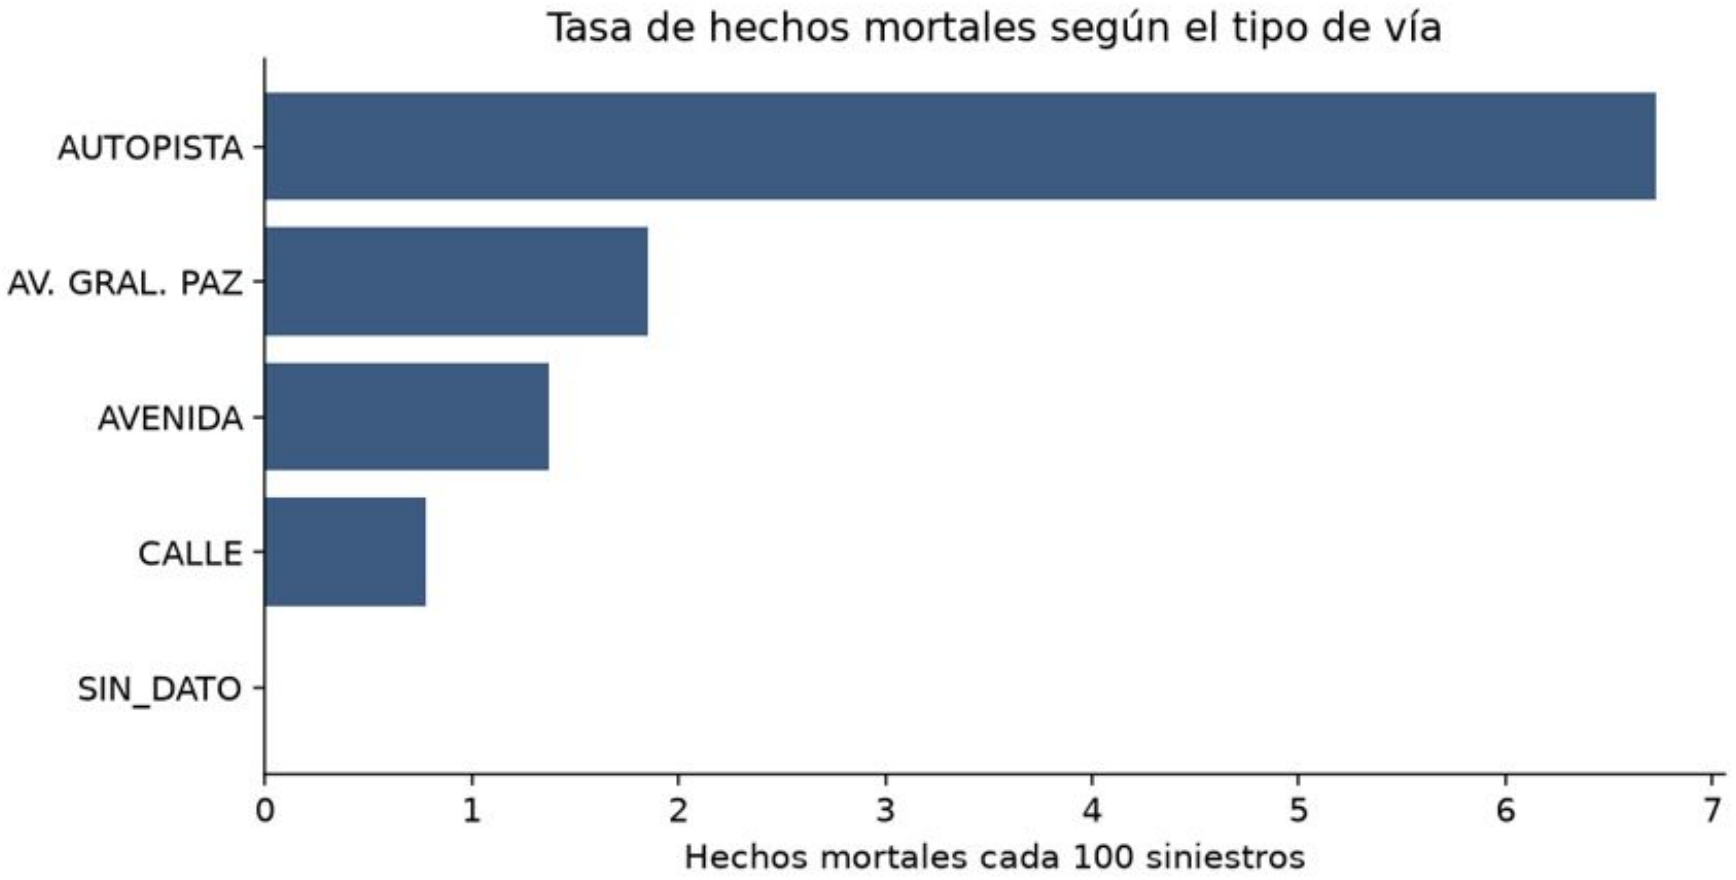

A la izquierda, el conteo de hechos. A la derecha, el conteo de hechos mortales. En 2020 los hechos bajan a 6.061, frente a 10.155 en 2019, y en 2025 llegan a 11.752. Los mortales se mantienen entre 79 y 110 por año. En 2025 la tasa es 0,77 %.

# Evolución anual, modo de desplazamiento y tipo de vía



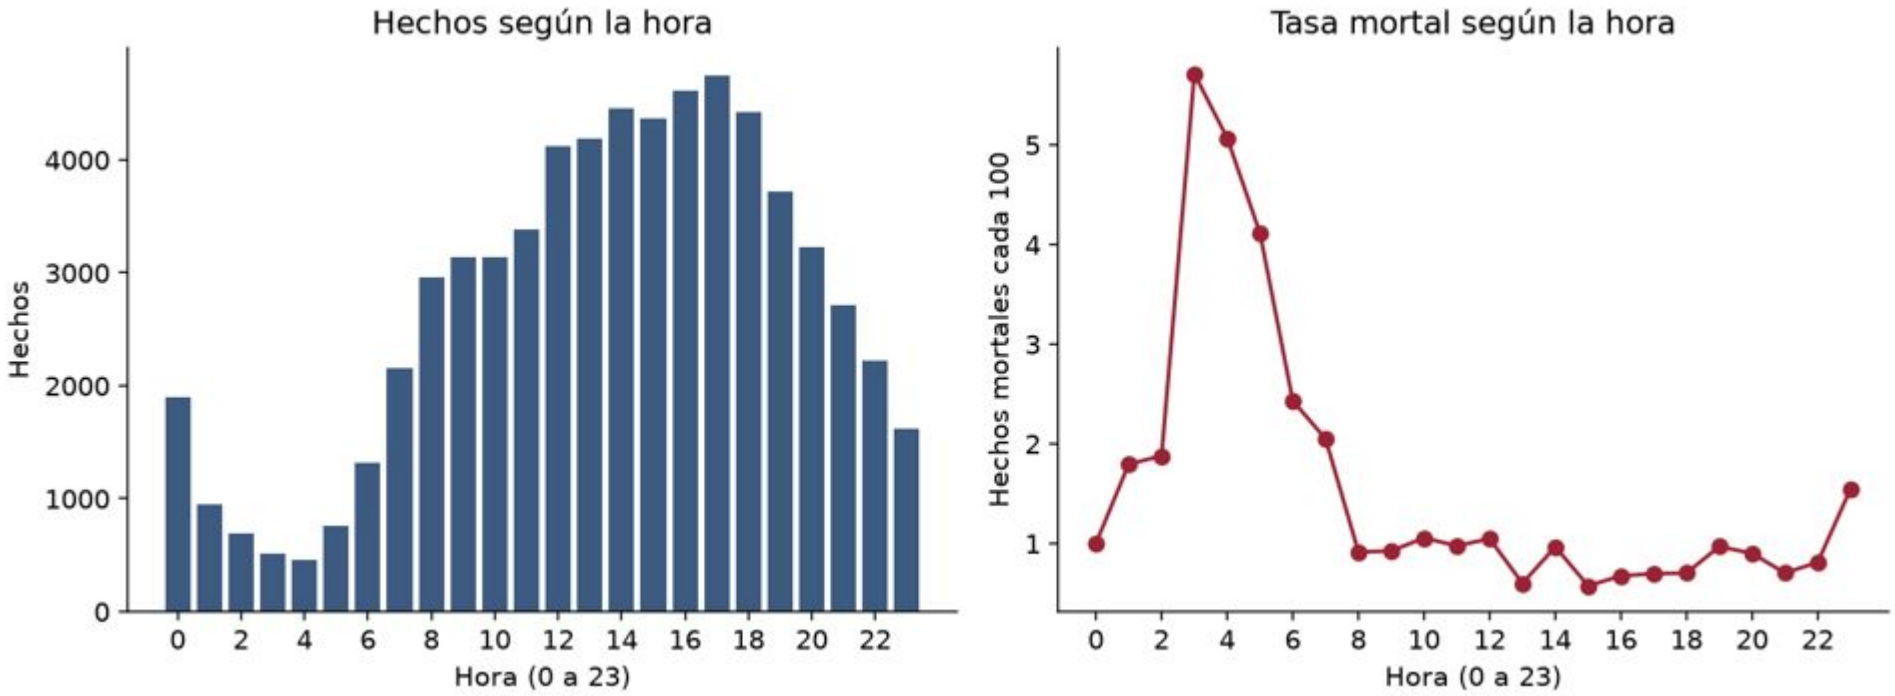

Tasa, no conteo. El peatón está en 2,86 % (269 hechos mortales). La moto está en 1,16 % y aporta 285. SIN_DATO queda en cero: 10.929 hechos sin modo, ninguno mortal.

# Evolución anual, modo de desplazamiento y tipo de vía




La autopista tiene 1.041 hechos y una tasa de 6,72 %. La calle queda en 0,78 %. SIN_DATO otra vez en cero.

# Franja horaria




A la izquierda, el conteo por hora. A la derecha, la tasa. Entre las 3 y las 5 ronda el 5 %. Esta figura descarta rellenar la hora vacía con la media.

# Reglas de limpieza del archivo

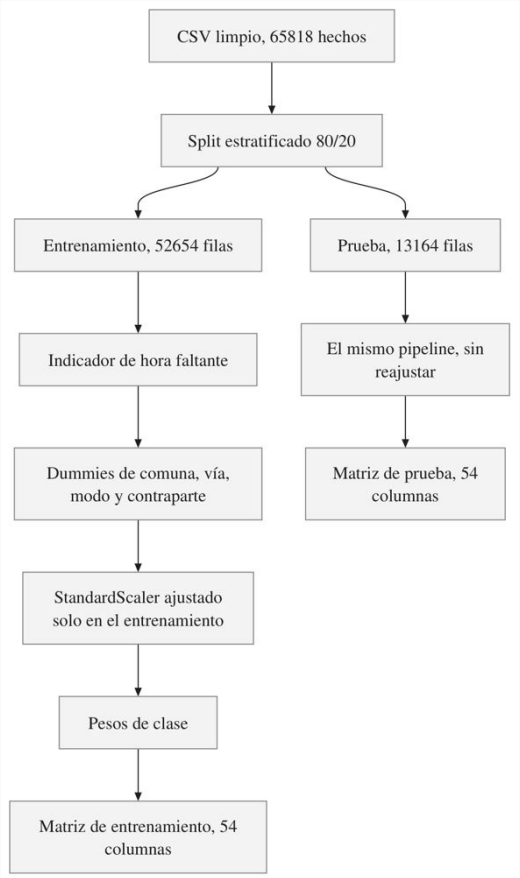
## Limpieza en data/siniestros_hechos_limpio.csv (12,8 MB)

- **Filas:** 65.818 sin descartes (36.579 modificadas, 29.239 intactas).
- **Texto:** Mayúsculas; vacío, SD y #¡REF! pasan a SIN_DATO (SD-AUTO se conserva).
- **Totales y fechas:** 3.276 filas de 2025 completadas con 1; HC-2025-0908572 pasa de 29 a 28.
- **Nulos y etiquetas:** 81 horas nulas y 3.031 coordenadas nulas; 31 leves con graves quedan LEVE.
- **Exclusiones:** Conteos por gravedad, prefijo HC/LC, participantes y coordenadas no entran.

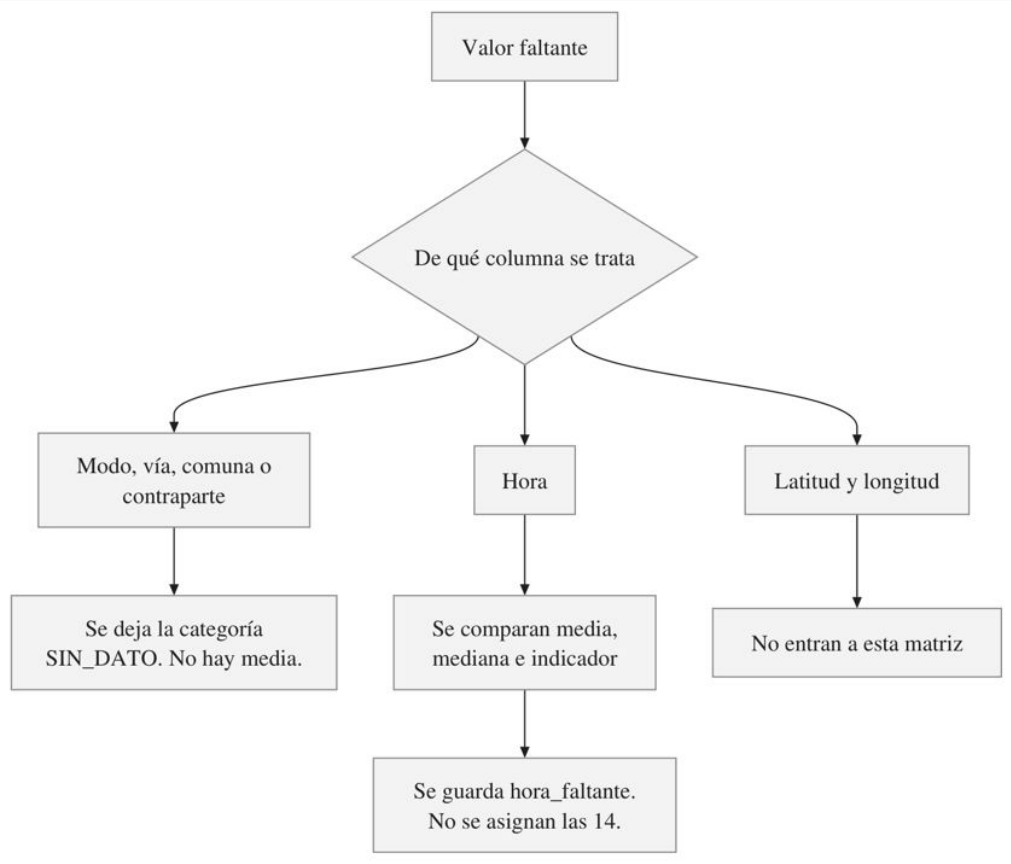
| id_siniestro | numero_tot | numero_vict | numero_vict | numero_vict | fecha_sinies | anio_siniest | mes_siniestr | dia_siniestr | hora_siniest | rango_horar | direccion_nc | comuna_sini | tipo_de_via | geocodificac | longitud_sin | latitud_sinie | participante | modo_despl | contraparte_ | gravedad_sir |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 01:55:00 | 1 | | Comuna 8 | AUTOPISTA | POINT (1018 | -5.844.351 | -34.669.125 | AUTO-UTILIT | AUTO | UTILITARIO | LEVE |
| LC-2019-0000 | 1 | 0 | 1 | 0 | 1/1/2019 | 2019 | 1 | 1 | 18:50:00 | 18 | DE LOS CONS | Comuna 12 | AVENIDA | POINT (9751 | -58.490.436 | -34.583.403 | MOTO-AUTC | MOTO | AUTO | GRAVE |
| LC-2019-0000 | 3 | 3 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 13:40:00 | 13 | | Comuna 11 | | POINT (9437 | -58.524.662 | -34.603.255 | AUTO-AUTO | AUTO | AUTO | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 07:15:00 | 7 | | Comuna 9 | | POINT (9403 | -58.528.413 | -34.650.156 | AUTO-CAMI( | AUTO | CAMION | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 12:24:00 | 12 | | Comuna 4 | | POINT (1053 | -58.404.748 | -34.648.387 | AUTO-MOVII | AUTO | MOVIL | LEVE |
| LC-2019-0000 | 4 | 4 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 04:30:00 | 4 | | Comuna 3 | | POINT (1059 | -58.398.225 | -34.604.579 | AUTO-TRANS | AUTO | TRANSPORTI | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 09:00:00 | 9 | | Comuna 14 | | POINT (1049 | -58.408.911 | -34.559.658 | BICICLETA-AI | BICICLETA | AUTO | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 07:30:00 | 7 | | Comuna 11 | | POINT (9487 | -58.519.116 | -34.589.282 | MOTO-AUTC | MOTO | AUTO | LEVE |
| LC-2019-0000 | 2 | 2 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 08:05:00 | 8 | | Comuna 15 | | POINT (1021 | -58.439.392 | -34.588.108 | MOTO-AUTC | MOTO | AUTO | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 09:36:00 | 9 | | Comuna 1 | | POINT (1084 | -58.371.488 | -34.598.416 | MOTO-AUTC | MOTO | AUTO | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 18:30:00 | 18 | | Comuna 9 | | POINT (9611 | -58.505.709 | -34.654.463 | MOTO-AUTC | MOTO | AUTO | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 21:46:00 | 21 | | Comuna 9 | | POINT (9550 | -58.512.313 | -34.661.307 | MOTO-AUTC | MOTO | AUTO | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 12:02:00 | 12 | | Comuna 7 | | POINT (1019 | -58.442.125 | -34.649.498 | PEATON-AU | PEATON | AUTO | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 02:30:00 | 2 | | Comuna 7 | | POINT (1023 | -58.437.425 | -34.647.349 | PEATON-MO | PEATON | MOTO | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 19:46:00 | 19 | | Comuna 1 | | POINT (1081 | -58.374.154 | -34.591.108 | PEATON-TRA | PEATON | TRANSPORTI | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 02:00:00 | 2 | | Comuna 8 | | POINT (9953 | -58.468.335 | -34.677.556 | SD-SD | SD | SD | LEVE |
| LC-2019-0005 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 03:00:00 | 3 | | Comuna 2 | | POINT (1058 | -58.399.038 | -34.598.285 | SD-SD | SD | SD | LEVE |
| LC-2019-0000 | 1 | 1 | 0 | 0 | 1/1/2019 | 2019 | 1 | 1 | 13:00:00 | 13 | | Comuna 4 | | POINT (1079 | -58.376.137 | -34.651.461 | TAXI-TRANS | TAXI | TRANSPORTI | LEVE |
| LC-2019-0002 | 1 | 0 | 1 | 0 | 2/1/2019 | 2019 | 1 | 2 | 15:18:00 | 15 | COLONIA AV | Comuna 4 | AVENIDA | POINT (1059 | -58.398.009 | -34.638.178 | MOTO-AUTC | MOTO | AUTO | GRAVE |
| LC-2019-0002 | 1 | 1 | 0 | 0 | 2/1/2019 | 2019 | 1 | 2 | 05:15:00 | 5 | | Comuna 13 | | POINT (9896 | -58.474.535 | -3.453.838 | AUTO-AUTO | AUTO | AUTO | LEVE |
| LC-2019-0002 | 1 | 1 | 0 | 0 | 2/1/2019 | 2019 | 1 | 2 | 15:27:00 | 15 | | Comuna 1 | | POINT (1082 | -58.373.748 | -34.604.635 | BICICLETA-T/ | BICICLETA | TAXI | LEVE |

# Preprocesamiento, faltantes y pesos de clase

Reparto 80/20 estratificado (semilla 42): 52.654 entrenamiento y 13.164 prueba. Matriz de 54 columnas (2 calendario, 2 hora, 50 dummies). Pesos: leve 0,353, grave 7,424, mortal 31,854.




El escalador se ajusta en el entrenamiento. La prueba usa el mismo pipeline, sin reajustarlo.



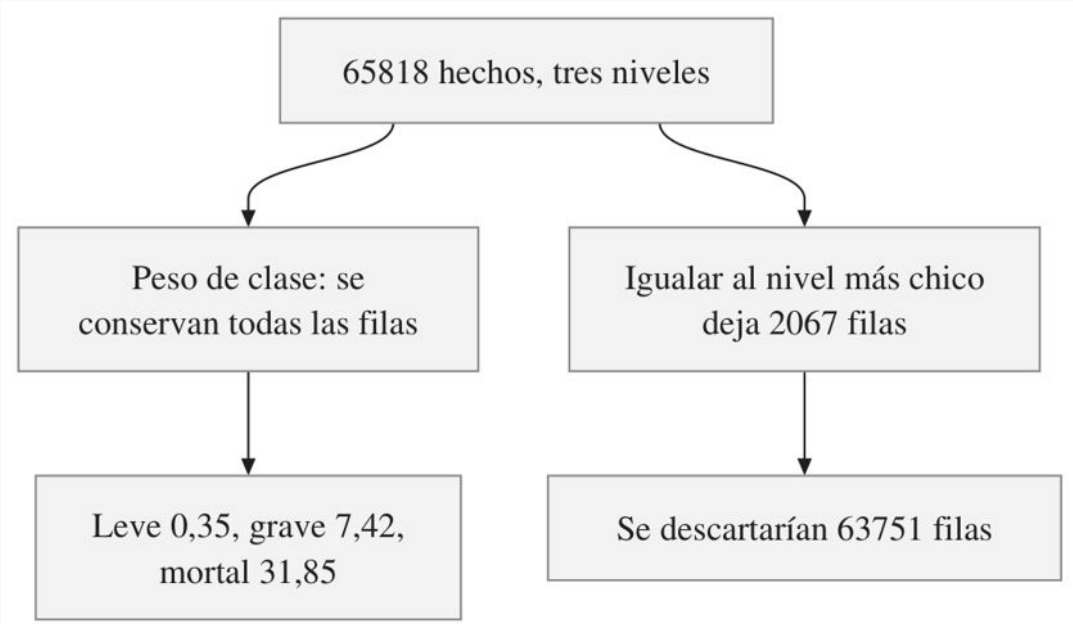

Tratamiento según el tipo de faltante. La hora vacía son 81 filas. Una es un hecho mortal.

# Preprocesamiento, faltantes y pesos de clase

Reparto 80/20 estratificado (semilla 42): 52.654 entrenamiento y 13.164 prueba. Matriz de 54 columnas (2 calendario, 2 hora, 50 dummies). Pesos: leve 0,353, grave 7,424, mortal 31,854.




62.174 leves, 2.955 graves y 689 mortales. Azul, leve. Amarillo, grave. Rojo, mortal. La tajada mortal es el 1 %.




El peso conserva las 65.818 filas. Igualar los tres niveles al tamaño de la clase mortal dejaría 2.067 filas.

# Criterio de elección y desempeño sobre toda la serie

### Nota para el lector: qué es el recall macro

El acierto es la proporción de filas bien clasificadas. Con un 94,5 % de leves, casi todo el acierto sale de ese nivel. El piso que predice siempre "leve" tiene acierto 94,5 % y recall 0 en grave y en mortal.

El recall de un nivel es la parte de los hechos que realmente fueron de ese nivel y que el modelo nombró bien. Si hay 138 muertes en la prueba y el modelo encuentra 117, el recall del mortal es 117/138 = 84,8 %.

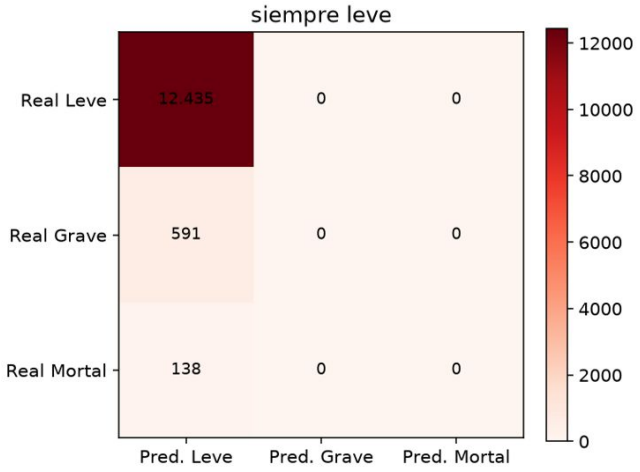
El recall macro es el promedio de los tres recall, el de leve, el de grave y el de mortal, sin ponderar por la cantidad de casos. Por eso el 94,5 % de leves no tapa al 1 % de muertes. Este trabajo elige el modelo por el recall macro de la prueba. Si hay empate, manda el recall del mortal y después el del grave. El acierto no elige.

La precisión es otra cosa: de los hechos que el modelo llamó graves, o mortales, cuántos lo eran. En el modelo elegido queda en 0,082 para el grave y en 0,041 para el mortal. Recupera casos y marca muchos de más.

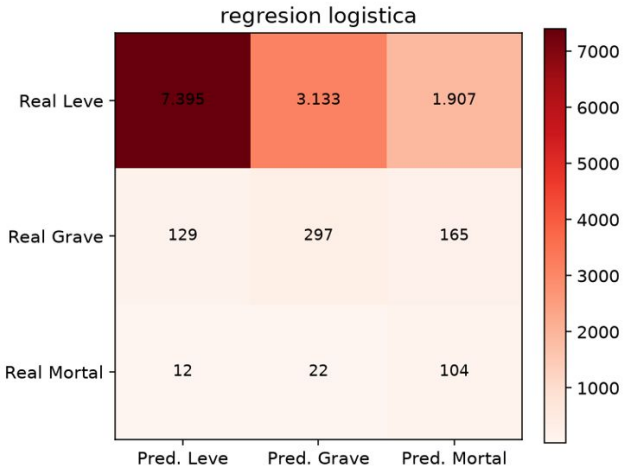
| Modelo (Prueba: 13.164) | Acierto | Recall Macro | Recall Grave | Recall Mortal |
|---|---|---|---|---|
| Siempre leve (piso) | 94,5 % | 33,3 % | 0 % (0/591) | 0 % (0/138) |
| Regresión logística | 59,2 % | 61,7 % | 50,3 % (297) | 75,4 % (104) |
| Árbol (prof. 5) | 65,7 % | 57,3 % | 19,3 % (114) | 84,8 % (117) |
| **Random forest (200 árb.)** | **54,8 %** | **62,1 %** | **46,7 % (276)** | **84,8 % (117)** |

**Lectura de matriz:** La fila es lo que pasó y la columna lo que dijo el modelo (orden: leve, grave, mortal). Se elige el random forest (recall macro 0,621).

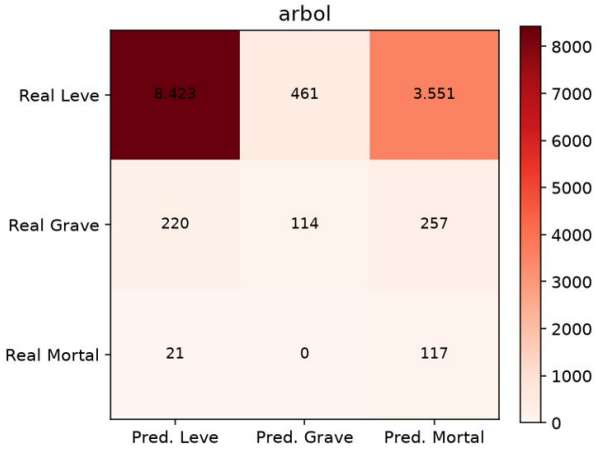
# Matrices de confusión en la prueba (2019-2025)



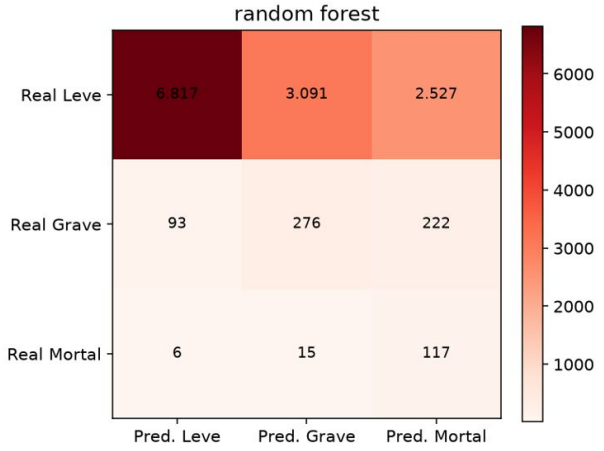

Piso. Acierta los 12.435 leves y no encuentra ningún grave ni ningún mortal. El acierto es 94,5 %.




Regresión logística. Encuentra 297 de 591 graves y 104 de 138 mortales. Llama leves a 12 muertes.



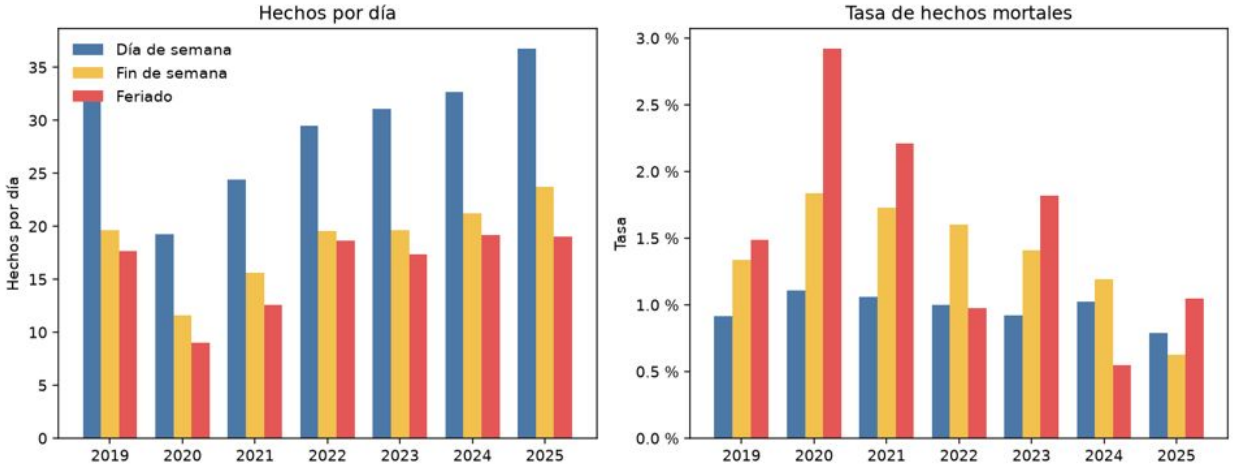

Árbol. Encuentra 117 de 138 mortales y solo 114 de 591 graves. El recall del grave queda en 19,3 %.



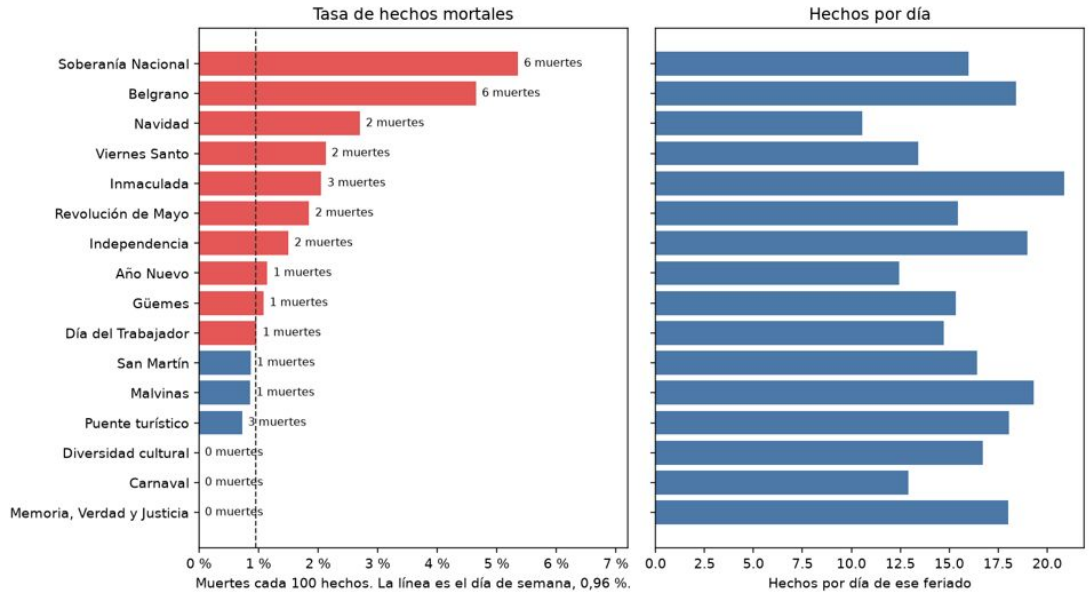

Random forest, el modelo elegido. Encuentra 117 de 138 mortales y 276 de 591 graves. De las 21 muertes que no nombra como mortales, 15 quedan como graves y 6 como leves.

# Feriados: reconstrucción del calendario y tasa mortal

**Marca (_calendario.py):** API 2021–2025 y regla de traslado 2019–2020. **Hechos/día:** Semana 29,4 (0,96 %), fin de semana 18,7 (1,33 %), feriado 16,3 (1,40 %, 31 muertes).

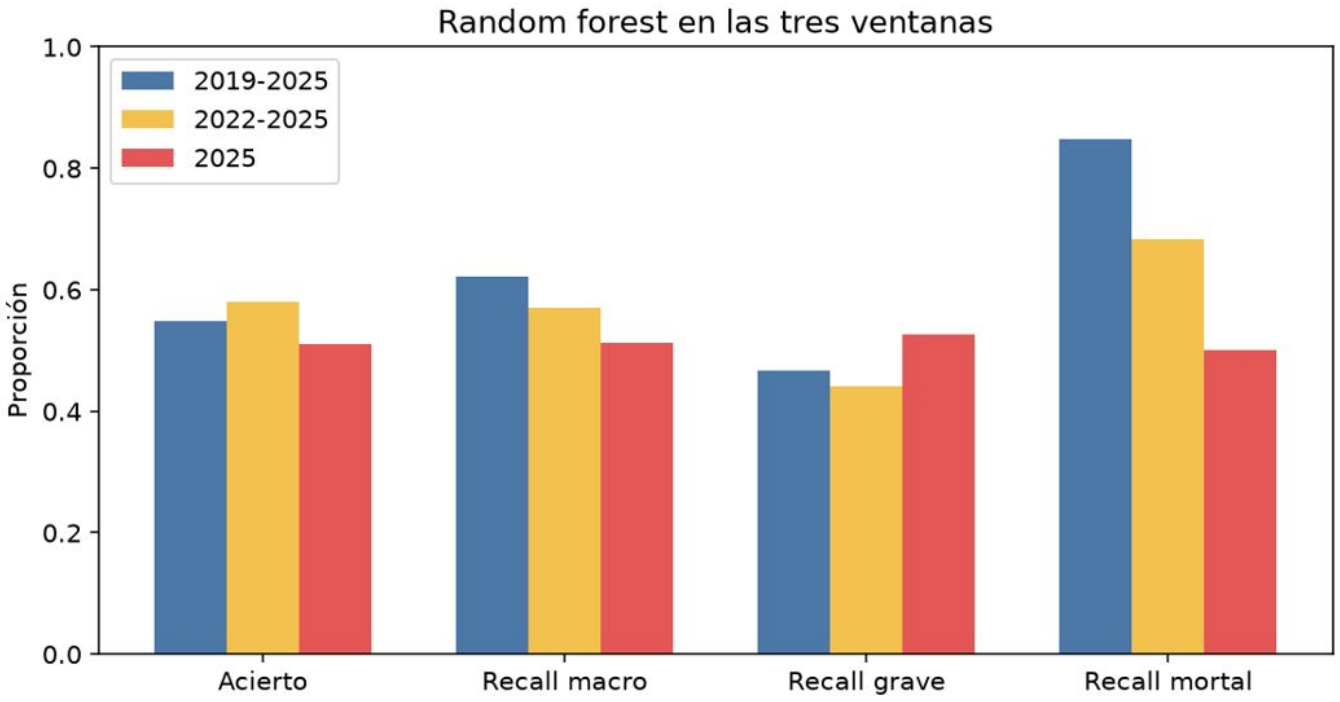



A la izquierda, hechos por día. A la derecha, la tasa de hechos mortales. El feriado que cae sábado o domingo entra en la barra roja.




Cada barra junta los días de ese feriado entre 2019 y 2025. La línea es la tasa del día de semana, 0,96 %. En rojo, el feriado que la supera. Carnaval y Día de la Memoria quedan en cero muertes.

# Recorte de la serie y estructura del código




Random forest en las tres ventanas. El acierto de 2019-2025 queda abajo porque el modelo no se elige por acierto. En 2025 el recall de la muerte baja: la prueba tiene 18 muertes.

## Efecto del recorte

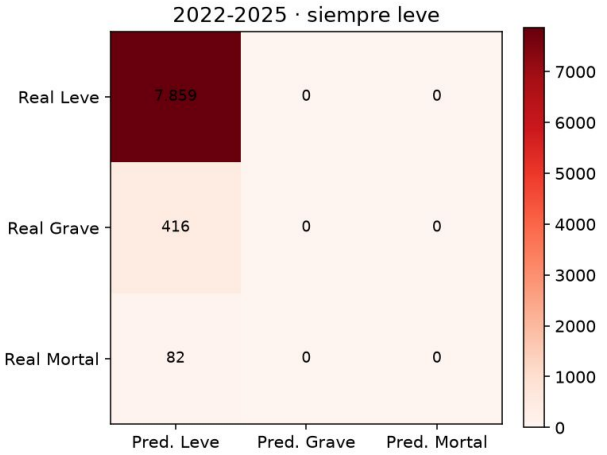
- **2022-2025:** 41.784 hechos (8,1 MB); forest recall macro 57,0 %, mortal 68,3 % (56/82).
- **Solo 2025:** 11.752 hechos (2,3 MB); prueba con 18 muertes (forest halla 9, logística 13).

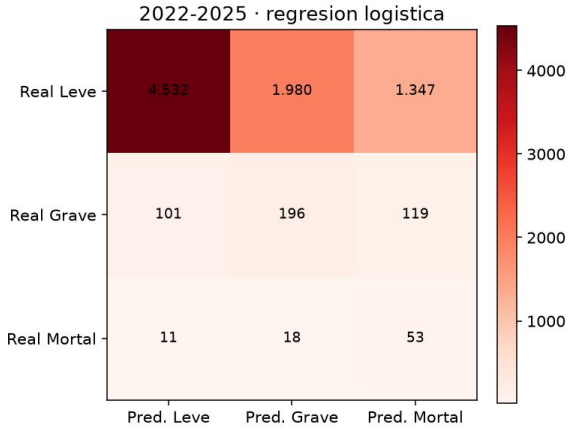
## Archivos de código

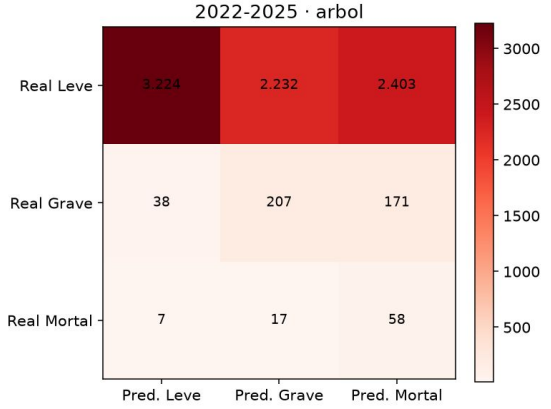
- **01_eda_limpieza.ipynb:** Limpia, calcula tasas y escribe CSV limpio y gráficos.
- **02_preprocesamiento.ipynb:** Parte 80/20, arma 54 columnas y guarda pipeline.joblib.
- **03_modelos.ipynb:** Evalúa por recall macro, guarda modelos.json y corre recortes.
- **_calendario.py y escala_hora.py:** Feriados y escalado de hora con indicador.

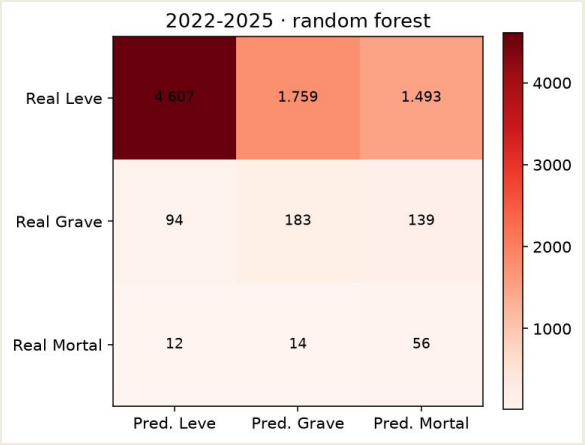
# Matrices de confusión en los recortes (2022-2025 y 2025)

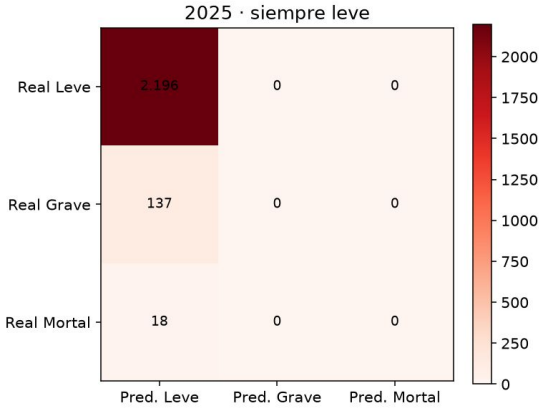
Arriba: ventana 2022–2025 (82 muertes y 416 graves en prueba). Abajo: ventana 2025 (18 muertes y 137 graves en prueba; piso siempre leve en 93,4 %).

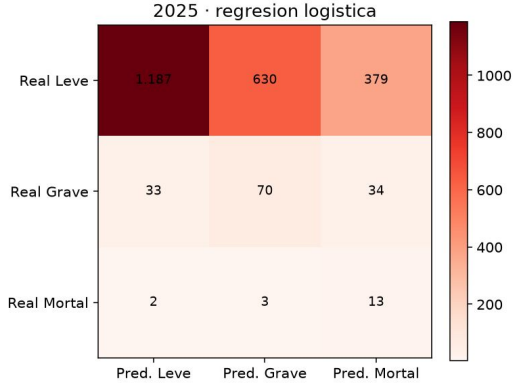


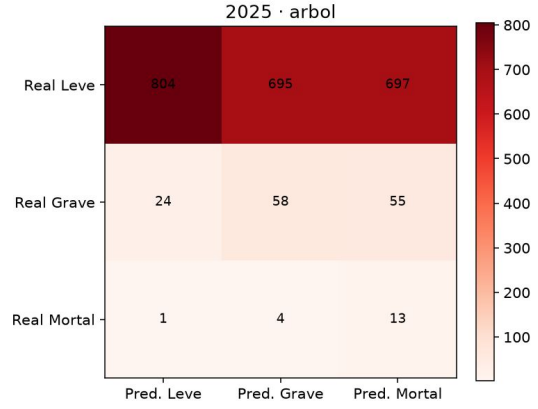



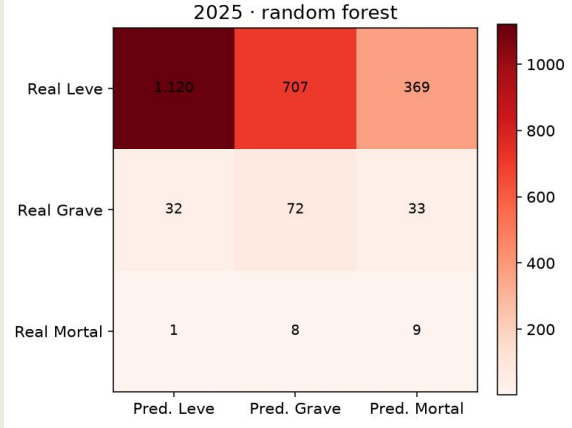



# Conclusiones, problemas y líneas futuras

## Conclusiones (en orden)

1. **Piso:** Con 94,5 % leves, decir siempre leve da 94,5 % de acierto y 0 graves/muertes.
2. **Modelo:** Random forest sostiene los tres recall (54,8 %, 46,7 %, 84,8 %; 117/138 muertes).
3. **Error contiguo:** De 138 muertes, 15 van a graves y 6 a leves; baja precisión.
4. **Calendario:** Hechos/día bajan en feriado (16,3), tasa mortal fin de semana supera semana (2019–2024).
5. **Recorte:** Achica la clase mortal (18 muertes en 2025); no reemplaza la serie completa.

## Problemas identificados

1. **Desbalance:** Sin pesos, el ajuste cae al piso de 49.739 leves.
2. **SIN_DATO:** Cero mortales en modo, vía y comuna; mide calidad del sumario.
3. **Hora y serie:** Hora lineal, bache 2020, 31 leves con graves y 1 muerte sin hora.
4. **Feriados:** Armado externo; tasa apoyada en 31 muertes.

## Líneas futuras

1. **Víctimas:** Cruzar edad y sexo del CSV de 4,1 MB.
2. **Total víctimas:** Probar inclusión y medir su peso dominante.
3. **Corte temporal:** Hora con seno/coseno y entrenar 2019–2023 para medir 2024–2025.

# Bibliografía

Ali, Y., Hussain, F. y Haque, M. M. (2024). Advances, challenges, and future research needs in machine learning-based crash prediction models: A systematic review. *Accident Analysis & Prevention*, 194, 107378. https://doi.org/10.1016/j.aap.2023.107378

Butt, M. S. y Shafique, M. A. (2025). A literature review: AI models for road safety for prediction of crash frequency and severity. *Discover Civil Engineering*. https://doi.org/10.1007/s44290-025-00255-3

Hamdan, N. y Sipos, T. (2025). Advancements in machine learning for traffic accident severity prediction: A comprehensive review. *Periodica Polytechnica Transportation Engineering*. https://doi.org/10.3311/pptr.40369

Gobierno de la Ciudad de Buenos Aires. (2026). *Víctimas de siniestros viales* [Conjunto de datos]. https://data.buenosaires.gob.ar/dataset/victimas-siniestros-viales

---

Síntesis documental: Ali, Hussain y Haque exigen tratar el desbalance explícitamente y no mezclar definiciones. Hamdan y Sipos ubican random forest entre los modelos más usados y destacan vía y usuario. Butt y Shafique orientan la utilidad hacia dónde intervenir en la gestión.